一页结论：哪类题答得好、哪类翻车、为什么

语料：16 家 A 股白酒公司 × (2026 半年报 + 2025 年报) = 32 份 PDF，切出 15,017 块 （正文 6,015 / 表格 9,002）。 **系统**：向量（百炼 text-embedding-v4，1024 维）+ BM25 → RRF 融合 → 同公司配额； 全景题另有旁路通道，**按公司取证**并产出一张覆盖地图。 **评测**：10 道题（含 4 道全景题 / 含点名的两家对比），判三个互不替代的维度 —— **召回**（块里有没有标准答案）、**回答**（模型答对没有）、**覆盖**（全景题该取到的公司 是不是都取到了被问的那个字段）。 **成绩：召回 9 / 10，回答 9 / 10，全景覆盖 3 / 4 题。** 唯一答错的是 Q1（口径）；唯一覆盖不全的是 Q9（15/16，天佑德酒缺「同比」那一列）。 逐题记录见 `data/eval_report.md`。

一、答得好的：答案落在单个块里、且该块渲染正常

单点事实题（Q2 水井坊亏损、Q3 五粮液营收、Q4 泸州老窖归母、Q5 茅台同比）**4 题全对**。 共同点：答案能在一个块里找到，且那个块的表格还原是干净的。

两处超出预期的表现：

- **Q3 自己换了取数路径**。五粮液 p7「主要会计数据」表渲染错位（表头行选错 + 列整体串位）， 营业收入压根不在里面。模型避开了它，从 p12「营业收入构成」取到 284.17 亿， 还自己验算 `(28,416,674,541.77 − 23,509,972,048.65) / 23,509,972,048.65 ≈ 20.87%` 与 表中标注一致。**检索到的是坏块，它绕过去了。**
- **Q5 主动辨口径**。指出管理层讨论里的「营业总收入 922.78 亿 / 同比 1.3%」与 「营业收入 +1.47%」是两个口径（前者含利息收入等），并说明不影响结论。

二、翻车的两类，根因都在表格

类型一 · 生成失败（Q1）：渲染伪影让模型不信正确的块

问金徽酒经营现金流净额。**正确的块就在上下文里** —— p49 合并现金流量表， 211,867,041.23 元，与 p7、p16 三处互相印证。

但模型答了 **195,709,201.66**，来自 p51 的**母公司现金流量表**。它的原话是：

> 片段[1]中同名项目出现两个数值……但其上下文为「将净利润调节为经营活动现金流量」附注表， 且**格式异常**（含冒号分隔的两组数字），无法清晰对应本期/上年同期；而片段[2]是主体现金流量表， 结构完整、单位明确，应以[2]为准。

它**看见了正确的数字，然后因为那个块的渲染难看而抛弃了它**。触发条件是表格识别把数值 塞进了列名位置：`收到的税费返还 | 1,922,635,320.51: 432,821.14`。模型把这个伪影读成 「格式不可信」，转投了格式干净、但口径错误的那份表。

这类错最危险：检索指标全绿，只有把「召回」和「回答」分开判才暴露。 修法在表头识别，不在提示词 —— 提示词里已经写了「合并/母公司口径要说清楚」，没有用。

类型二 · 覆盖失败（Q9）：全景通道的质量上限 = 锚点块的质量上限

（前三轮修供证、第四轮修摆法；**回答已稳，覆盖仍判 15/16**）

问哪几家营收同比正增长。正确答案 4 家，其中 **五粮液 +20.87% 是 16 家里增速最高的**。

改之前，全景通道给每家取一个「主要会计数据」块。五粮液的锚点就是那张坏掉的 p7 表 —— **不含营业收入，也不含 20.87%**。增速最高的那一家从未进入上下文，模型只好写 「五粮液……该片段未提供营业收入同比增减率 → 无法判断」。

16 个锚点坏 1 个，那一家就从全景视野里整个消失，而且不报警。 这是旁路通道的结构性代价： 它绕过了相似度排序，就也失去了「排名靠后所以大概不重要」这层兜底。 更麻烦的是模型**只会说「无法判断」，不会说「我缺了一家的数据」** —— 缺口对下游不可见。

改法不是调检索，是把「取证」变成一件要交账的事，三处一起动：

1. **按公司取证**。锚点上先校验被问的字段在不在；不在就回退到该公司别的块继续找 （五粮液 → p12 收入构成表 `28,416,674,541.77 / 同比增减 20.87%`； 天佑德酒 → p45 第 45 页利润表 `574,885,860.71 / -14.68%`）。 取证仍然**一家一块**，上下文规模没涨。
2. **覆盖地图进上下文**。每家一行：状态（✅ 已覆盖 / ⚠️ 部分覆盖 / ❌ 缺据）、 取值、项目、期次、口径、取自哪一页哪条路径（锚点 / 回退），以及它对应哪个片段号。 提示词据此强制模型**点名说明缺哪几家、缺的是哪一项**，且不许拿别家的数替它补上。
3. **禁止没有数值的带过**。筛选题必须逐家给出数值与出处；结论必须与所列数值**逐条对得上**。

三处都生效了，但不是一次到位 —— 中间那轮暴露了新问题：模型把 15 家逐家列了出来 （数字全对），结论却仍写「共 2 家」，还把 +1.47% 和 +20.87% 归进「其余 13 家均同比下降」， 列表与结论打架。自动判定当时放它过了（四个名字都在文中，子串判定抓不住）， 是人工复核发现后补了一条「结论家数必须与列表一致」的断言，才判出 ✗。

以为修好了，一截图又漏了五粮液 —— 这才是最值得写下来的一轮。 那一版的覆盖地图只摆「营业收入 = 28,416,674,541.77」，**没摆同比那一列**， 而问句问的正是同比。模型于是自己回 16 张原文表里翻同比；五粮液那一行的同比恰好 挂在一条**丢了行标签**的数据上：

```
本报告期: 28,416,674,541.77 | 本报告期: 100% | ... | 同比增减: 20.87%
```

认不出这个 20.87% 是谁的，于是这家全场增速最高的公司再一次整个消失， 还写下「其余 12 家同比均为负增长（见覆盖地图所列同比数值），无例外」—— 它嘴里念着地图，结论却跟地图打架。**实测 4 次只对 1 次。**

第四轮改的是**摆什么**，不是怎么问：

1. **摆被问的那一列。** 覆盖地图每行同时给「值 + 同比」。同理，覆盖门槛从 「块里有同比字样」收紧成「**这一行的同比也取到了**」—— 否则一家没披露同比的 公司会被它下面「利润总额」那行的同比顶成已覆盖，数还是错的。
2. **按同比降序排。** 正号挤成一段前缀，名单变成"开头这几行"。
3. **末尾给一行方向小计**（正 4 家 / 负 11 家 / 不可判断 1 家）当对账数。

这一轮的验证是能算的：15 家的同比全部满足「本期 ÷ 上年同期 − 1 = 取到的同比」 （误差 < 0.02 个百分点）—— 证明取的是本行的值，不是邻行的。改后连跑 6 次 （探针 4 次 + 全量评测 2 次）全部答对 4 家，且不再出现「修正：」式的自我更正。

但有一处取舍必须写在明面上：方向小计是**系统替模型做的那次计数**。它只说 「有几家」，不说「是哪几家」，名单仍要模型按公司名列出 —— 可这道题「回答」这一维的 含义就此变了：从「模型会不会数 16 行」变成

「模型会不会照账列名单」。 老师说「核齐全部公司」该由系统负责，这是落地；但**指标变了，不能拿它跟前几轮对标**。

覆盖仍判未通过：15/16，天佑德酒 partial。 它 2026 半年报的主表丢了行标签， 全库没有任何一个块同时带「营业收入」和「同比」那一列，只能明说缺哪一列。 模型对此的处理是对的（点名、不计入判断），但 15 ≠ 16 —— **覆盖不完整就是覆盖不完整**， 这正是「缺据明说」要如实呈现的东西，不因为答对就改判。

三、全景题的规律（4 题：3 对 1 覆盖不全）

	问法	对覆盖完整性的要求	回答	覆盖
Q6	点名**两家**对比	只核这两家（覆盖范围跟问句走）	✓	✓ 2/2
Q7	谁**最高**（极值）	只要**一家**对就成立，容错最高	✓	✓ 16/16
Q8	哪几家**为负**（异常值）	少数派扎眼，模型会主动翻遍 16 块	✓	✓ 16/16
Q9	哪几家**满足条件**（方向筛选）	**每家**都得在场且字段完整，容错为零	✓	✗ 15/16

- **Q6 的覆盖范围按问句收敛**：只点名两家就只核两家，上下文从 6 块涨到 8 块。 早先的版本会把 16 家全塞进来（→22 块），对一道两家对比题是纯浪费。
- **Q8 的克制质量最高**：主动排除了两类假命中 —— 子公司口径的数（曲阜孔府家 −280 万）、 以及联营企业财务信息摘要。这两类现在都在取证层就被拦下（整块不算命中）， 不指望模型每次都能识破。
- **Q9 那一格 ✗ 指覆盖，不指回答**。这正是三维分开判的价值：Q9 的答案对了， 但支撑它的取证**缺了一角**，两个指标结论相反，都必须如实写出来。

四、总判断

- **单块可取的事实题：稳。** 连「主表坏了」都能绕路取到（Q3）。
- **全景题：从「凭一个锚点断言」变成「逐家取证 + 缺据明说」。** Q9 之前是**静默消失**， 现在是**显式缺项**——这是本次改造最实质的变化：把不可见的缺口变成可追责的记录。
- **Q9 还教了一件事：证据齐备 ≠ 结论正确。** 第四轮那版的地图，16 家的证据一应俱全、 五粮液那行白纸黑字写着 +20.87%，模型照样写「其余各家均为负增长」。缺的从来不是证据， 是**模型没有能力对 16 行同构数据做一次可靠的计数**。所以最后的修法是让系统把这一列 **排好序、并把总数摆出来对账**，模型只负责按名列举。凡是要在全景题上做统计， 都该按这个分工走：**系统核账，模型叙述**。
- **剩下的两类失败，根因都在表格渲染，不在检索算法或提示词**： – Q1 的口径错：数值串进列名位置，模型不信正确的块； – Q9 的覆盖缺：天佑德酒主表丢行标签，导致「营业收入 + 同比」不在同一个块里。 – 还有一类是**口径标注**：第八节的块内分不出合并/母公司（金徽酒 p49 合并现金流量表 与 p51 母公司现金流量表的 section / unit / 文本前缀完全一致），覆盖地图只能记 「未标注」——**能做多少说多少，不猜**。
- **防编造是可靠的**。Q10 问语料外的顺鑫农业，模型干净拒绝。它栽在**读错源数据**， 不是**凭空造数**。

五、已知未修（都指向表格）

1. **表头行误判 → 数值串进列名位置**（Q1 根因）。重复度不够高， 已有的 `TABLE_DUP_RATIO` 闸门拦不住 —— 那是为「整页重复」设计的，这是「局部错位」。
2. **五粮液 p7、天佑德酒 p8 两张主表渲染错位 / 丢标签**（Q9 覆盖缺项的根因）。 聚合层已经能用「回退 + 缺据」兜住它（五粮液不再消失；天佑德酒如实标部分覆盖）， 但**根还在 `parse.py` 的表头识别**：要真正修好，得从表格 bbox 上方的页面横幅里 抓报表标题，代价是重建索引（1,498 次 embedding 调用）。
3. **口径标注不可靠**。第九节的块内分不出合并 / 母公司，覆盖地图只能记「未标注」； 第二节主表的口径是**按披露制式规则推定**的（写成「合并（第二节主表·规则推定）」， 标明这是推的，不是从行文里读出来的）。
4. **top-k 通道未按期次过滤**：问 2026 半年报，召回里混进了口子窖 2025年报 的块。 全景通道有 `_report_rank` 收敛期次，普通通道没有。

另有一处**已知取舍**：19 张检测出来的「表」是整页文字重复十几遍的误检块，已整张拒绝、 交回正文路径（数字一个没丢，但列与列的对应退化成按行排列）。占全库 0.24%。